

자연어 분석과정

- 1. 형태론(Morphology): 단어와 형태소를 연구
- 2. **통사론(syntax)**: 문법적 구조분석(Parsing)
- 3. **의미론(Senmantics) :** 단어 의미차이 ex) 뉘앙스, 톤, 의도(긍/부정)

Phrase 토란활용

불용어 처리

단어의 활용

Stop Words

- 1. 연관성이 낮은 단어들을 제외하고 분석
- 2. 내용과 목적에 따라서, 불용어 처리여부 및 해당 목적에 맞는 불용어 말뭉치 DB등을 판단해야 한다

Stop Words

```
In [10]: texts = 'I like such a Wonderful Snow Ice Cream'
    texts = texts.lower()
    texts

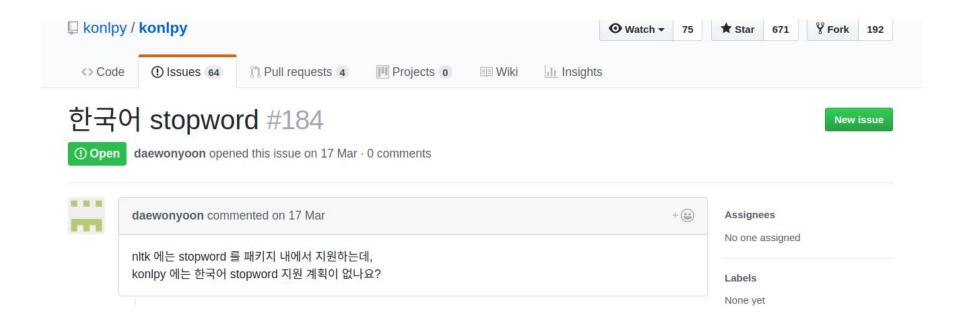
Out[10]: 'i like such a wonderful snow ice cream'

In [11]: from nltk import word_tokenize
    tokens = word_tokenize(texts)
    tokens

Out[11]: ['i', 'like', 'such', 'a', 'wonderful', 'snow', 'ice', 'cream']
```

Stop Words

한글의 경우



한글의 경우

```
In [14]: f = open('./data/한국어불용어100.txt', 'r')
         s = f.read(); f.close()
         stop_words = [ txt.split('\t')[:2] for txt in s.split('\n') ]
         stopword = {}
         for txt in stop_words:
            try: stopword[txt[0]] = txt[1]
            except: pass
         stopword
Out[14]: {'0|': 'NP',
         '있': 'VA',
          '하': 'VV',
          '것': 'NNB',
```

'있': 'VA', '하': 'VV', '것': 'NNB', '들': 'VV', '그': 'MM', '되': 'VV', '수': 'NNB', '보': 'VX', '않': 'VX',

Stop Words 사용자 정의 방법

- 1. 분야별(주식,리포트,연설문) 정제된 자료를 수집한 뒤
- 2. Token을 나눈 뒤 **빈도대비 중요도**를 측정
- 3. 빈도대비 중요도 측정결과를 저장 및 활용
- 4. 측정은 후술할 tf-idf 등을 활용

Phrase N-Gram

N-Gram

Token 집합

N Gram

- 1. 문장,절의 비교 분석시 token 갯수 일치가 필요
- 2. 독립적 / 균일한 관리 가능한, 분류기준이 필요

N Gram

N = 1 : This is a sentence unigrams: this, is, is, a, sentence

N = 2 : This is a sentence bigrams: this is, is a, a sentence

N = 3: This is a sentence trigrams: this is a, is a sentence

N Gram

```
In [1]: # 독일 퀘르버 재단 연설문 : 베를린 선언
       f = open('./data/베를린선언.txt', 'r')
       texts org = f.read()
       f.close()
In [2]: from nltk.tokenize import word_tokenize
       word_token = word_tokenize(texts_org)
In [3]: from nltk.util import ngrams
       texts_sample = [txt for txt in ngrams(word_token, 3)]
       texts_sample[:5]
Out[3]: [('존경하는', '독일', '국민'),
        ('독일', '국민', '여러분'),
        ('국민', '여러분', ','),
        ('여러분', ',', '고국에'),
        (',', '고국에', '계신')]
```

PMI

N-gram 상관분석

Point wise Mutual Information

점 위치 상호관계를 활용한 정보

- 1. 단어간의 거리를 비교측정하여 객체의 상관성을 분석한다
- 연어 (근접어:collocation) 관계 활용하여 분석가능한 객체를 생성한다 (Bi-gram, Tri-gram)
- 3. PMI는 단어간의 상관관계 확률론을 근거로, 단어간의 독립을 가정할 때 발생확률 과 문서에서 측정된 동시발생확률 을 비교하여 상관성을 분석한다

PMI - 한글만 추출

```
In [27]: from nltk.tokenize import RegexpTokenizer
re_capt = RegexpTokenizer('[가-힣]\w+')
raw_texts = re_capt.tokenize(texts_Berlin_raw)
raw_texts[:10]

Out[27]: ['존경하는', '독일', '국민', '여러분', '고국에', '계신', '국민', '여러분', '하울젠', '쾨르버재단']

In [28]: texts = ''
for txt in raw_texts:
    texts += txt + " "
texts[:200]
```

Out[28]: '존경하는 독일 국민 여러분 고국에 계신 국민 여러분 하울젠 쾨르버재단 이사님과 모드로 동독 총리님을 비롯한 내외 귀빈 여러분 먼저 냉전과 분단을 넘어 통일을 이루고 힘으로 유럽통합과 국제평화를 선도하고 있는 독일과 독 일 국민에게 무한한 경의를 표합니다 오늘 자리를 마련해 주신 독일 정부와 쾨르버 재단에도 감사드립니다 아울러 얼마 별세하신 헬무트 총리의 가족'

PMI - 한글에 태그를 추가

Wall time: 3.6 s

CPU times: user 8.57 s, sys: 230 ms, total: 8.8 s

```
In [6]: %%time
# 베를린 선언문에 Tag 속성 추가하기
from konlpy.tag import Okt
twitter = Okt()
tagged_words = twitter.pos(texts, stem=True)
```

PMI - 연어관계 객체를 생성한 뒤, 객체 상위 PMI Bi-gram 출력

```
In [30]: from nltk import collocations
         finder = collocations.BigramCollocationFinder.from words(tagged words)
         finder
Out[30]: <nltk.collocations.BigramCollocationFinder at 0x7fc643f2ddd8>
In [31]: # top 10 n-grams with highest PMI
         measures = collocations.BigramAssocMeasures()
         finder.nbest(measures.pmi, 10)
Out[31]: [(('가능하며', 'Adjective'), ('불가', 'Noun')),
         (('가스', 'Noun'), ('관', 'Noun')),
          (('가운데', 'Noun'), ('현재', 'Noun')),
          (('감사', 'Noun'), ('드립니', 'Verb')),
          (('갖춰', 'Verb'), ('지', 'PreEomi')),
          (('같은', 'Adjective'), ('공감', 'Noun')),
         (('거나', 'Eomi'), ('깨져', 'Verb')),
         (('건너지', 'Verb'), ('않기', 'Verb')),
         (('걷어', 'Verb'), ('차는', 'Verb')),
          (('검증', 'Noun'), ('가능하며', 'Adjective'))]
```

PMI - 연어관계 객체를 생성한 뒤, 객체 상위 PMI Tri-gram 출력

```
In [32]: finder = collocations.TrigramCollocationFinder.from words(tagged words)
         finder
Out[32]: <nltk.collocations.TrigramCollocationFinder at 0x7fc643f2db70>
In [33]: measures = collocations.TrigramAssocMeasures()
         finder.nbest(measures.pmi, 10)
Out[33]: [(('가능하며', 'Adjective'), ('불가', 'Noun'), ('역적', 'Noun')),
         (('가스', 'Noun'), ('관', 'Noun'), ('연결', 'Noun')),
          (('가운데', 'Noun'), ('현재', 'Noun'), ('생존', 'Noun')),
          (('같은', 'Adjective'), ('공감', 'Noun'), ('대', 'Suffix')),
         (('거나', 'Eomi'), ('깨져', 'Verb'), ('서도', 'Noun')),
         (('검증', 'Noun'), ('가능하며', 'Adjective'), ('불가', 'Noun')),
         (('견', 'Noun'), ('지하', 'Noun'), ('면서', 'Noun')),
         (('과도', 'Josa'), ('같은', 'Adjective'), ('공감', 'Noun')),
         (('들어서는', 'Verb'), ('대전', 'Noun'), ('환', 'Noun')),
          (('록', 'Eomi'), ('앞장서서', 'Verb'), ('돕겠', 'Verb'))]
```

Tf-idf

상대빈도분석

- 1. 문서의 내용을 쉽게 벡터로 표현하는 고전적 방식
- 2. Term Frequency: 특정 용어의 발생빈도
- 3. (문서 Token 출현빈도) / (문서 전체 Token 갯수)
- 4. Inverse Document Frequency (문서 빈도의 역)
- 5. 문서를 이해하는데 Token의 중요도
- 6. 일반 문서대비 출현빈도

- 1. TF는 해당 문서만 있으면 바로 연산이 가능하지만
- 2. IDF는 모집단의 Corpus 별 통계값 (일반문서의 Token 출현빈도)이 있어야 연산가능

Commonly Used Terms

Tag Name	food	cakes	cooking	song	music
itunes	0.00019	0.00062	0.00080	0.02106	0.02319
food	0.04970	0.02544	0.01890	0.00024	0.01136
podcast	0.00842	0.00120	0.01538	0.01568	0.02053
government	0.01080	0.00108	0.00592	0.00022	0.00340
comics	0.00364	0.00282	0.00055	0.00229	0.01021
baking	0.04971	0.02544	0.02147	0.00018	0.00125
cooking	0.04450	0.02249	0.02347	0.00018	0.00108
dessert	0.02290	0.02739	0.02819	0.01488	0.01337
recipe	0.02162	0.00956	0.01830	0.00019	0.00019
foodblog	0.04971	0.01034	0.01538	0.00019	0.00013

	name character	token_stem character	count_per_doc ✓ integer	count_of_docs ✓ integer	tfidf v
111	Akebono Brake Corporation	act_euro	1	1	0.0809
112	Akebono Brake Corporation	act_euro_flyer	1	1	0.0809
113	Akebono Brake Corporation	aftermarket	1	2	0.0687
114	Akebono Brake Corporation	aftermarket_brake	1	1	0.0809
115	Akebono Brake Corporation	aftermarket_brake_usa	1	1	0.0809
116	Akebono Brake Corporation	akebono	3	1	0.2426
117	Akebono Brake Corporation	akebono_brake	2	1	0.1617
118	Akebono Brake Corporation	akebono_brake_trust	1	1	0.0809
119	Akebono Brake Corporation	akebono_proud	1	1	0.0809
120	Akebono Brake Corporation	akebono_proud_manufactur	1	1	0.0809
101	A1 1 5 1 6	Lesson Lesso			2 2225

TF - IDF (트럼프 취임연설문 불러오기 / 전처리)

```
In [1]: f = open('./data/trump.txt', 'r')
        texts = f.read()
        f.close()
In [2]: texts = texts.lower()
        from nltk.tokenize import RegexpTokenizer
        re_capt = RegexpTokenizer(r'[a-z]\w+')
        token = re capt.tokenize(texts)
        token[:10]
Out[2]: ['chief',
         'justice',
         'roberts',
         'president',
         'carter',
         'president',
         'clinton',
         'president',
         'bush',
         'president']
```

TF - IDF (Stop Word)

Out[4]: 'chief justice roberts president carter president clinton president bush president obama fel low americans people world thank citizens america joined great national effort rebuild count ry restore promise people together determine course america world many many years come face challenges confront hardships get job done every four years gather steps carry orderly peace ful transfer power grateful president obama first lady michelle obama gracious aid throughout transition magnificent thank today cere'

TF - IDF (Tf-idf 학습객체 생성)

```
In [6]: from sklearn.feature_extraction.text import TfidfVectorizer
        tfidf vec = TfidfVectorizer()
        transformed = tfidf_vec.fit_transform(raw_documents = [document])
        transformed
Out[6]: <1x455 sparse matrix of type '<class 'numpy.float64'>'
                with 455 stored elements in Compressed Sparse Row format>
In [7]: import numpy as np
        transformed = np.array(transformed.todense())
        index value = {i[1]:i[0] for i in tfidf vec.vocabulary .items()}
        fully indexed = {index value[column]:value for row in transformed
                                                    for (column, value) in enumerate(row)}
```

TF - IDF (Numpy 결과를 Pandas Series 객체로 변환/ 조회하기)

```
In [8]: import pandas as pd
        tfidf = pd.Series(fully_indexed).sort_values(ascending=False)
        tfidf[:10]
        /usr/lib/python3.6/importlib/ bootstrap.py:219: RuntimeWarning: numpy.dtype size changed, may indicate binary incom
        patibility. Expected 96, got 88
          return f(*args, **kwds)
        /usr/lib/python3.6/importlib/_bootstrap.py:219: RuntimeWarning: numpy.dtype size changed, may indicate binary incom
        patibility. Expected 96, got 88
          return f(*args, **kwds)
Out[8]: america
                   0.423714
        american 0.233042
        people 0.211857
        country 0.190671
        nation 0.190671
                  0.169485
        one
                  0.148300
        every
                  0.127114
        great
                   0.127114
        never
                   0.127114
        new
        dtype: float64
In [9]: tfidf['obama']
Out[9]: 0.06355703979105537
```